



Billion-scale Commodity Embedding for E-commerce Recommendation in Alibaba

Abstract

중국의 C2C 플랫폼 타오바오 (Taobao) 는 scalability, sparsity and cold start 문제가 있었는데 해결 방법이 있다. 그래프 임베딩 프레임워크를 기반한다.

유저 히스토리로 아이템 그래프를 구축하고 , 그래프 내의 모든 아이템의 임베딩을 학습한다. sparsity와 cold-start 문제를 완화하기 위해서, 부수적인 정보는 그래프 임베딩 프레임워크에 통합된다.

두가지 aggregation 방법을 제시한다.

INTRODUCTION

가장 중요한 문제는 어떻게 필요로 하거나 흥미로운 아이템을 빠르게 추천하는가?다.

세 가지 문제는 기존의 collaborate filtering, content-based, deep 로 추천 하는 것을 어렵게 만든다.

- Scalability : 추천 시스템 기술이 작은 데이터 셋에는 대체로 잘 동작하지만, 천만 유저와 이천만 아이템의 데이터 크기에서는 실패하게 된다.

- Sparsity : 유저가 작은 수의 아이템들과 상호 작용을 하기 때문에 학습하기가 어렵다.
- Cold Start : 수 백개의 새로운 아이템이 매 시간 마다 업로드 되고 그 아이템에 대한 유저의 행동은 없다.

그래서 두 스테이지로 구성된 추천 플랫폼을 디자인 했다. 매칭 스테이지와 랭킹 스테이지. 두 스테이지의 목적은 다르고 기술적인 해결 방법 분리를 이끌어 냈다.

매칭 스테이지는 코어 태스크가 모든 아이템 간의 유사도를 계산하는 것이다. 유저의 행동에 기반해서. 유사도를 얻은 후 랭킹 스케이지에서는 좀 더 개인화된 아이템 후보 셋을 생성한다.

이러한 것들을 하기 위해서, 아이템 그래프를 유저 행동 히스토리로 구축하고 SOTA의 그래프 임베딩 방법을 적용해 각 아이템의 임베딩을 학습한다. (dubbed Base Graph Embedding, BPE) 아이템들의 임베딩 벡터들의 내적으로 계산한 유사도로 후보 아이템 셋을 생성할 수 있다.

과거에는 CF 모델을 사용했었다. 그러나, CF 기반의 메소드들은 유저 행동 히스토리에 함께 등장한 아이템 들만 고려한다.

본 논문에서는 아이템 그래프 내의 Random Walk를 사용한다. 더 높은 차원의 유사도를 획득 할 수 있기 때문에 CF에 기반한 방법보다 우수하다.

정확도를 높이기 위해서 dubbed Graph Embedding with Side Information (GES) 라는 임베딩에 부가 정보를 합치는 방식을 제안한다.

부가 정보가 수백 개가 되어, 가중치를 포함하는 dubbed Enhanced Graph Embedding with Side Information (EGES)로 임베딩을 부가 정보와 함께 학습하는 메커니즘을 제안한다.

Framework

2.1 Preliminaries

Deep Walk : 그래프 내의 각각의 노드의 임베딩을 학습한다.

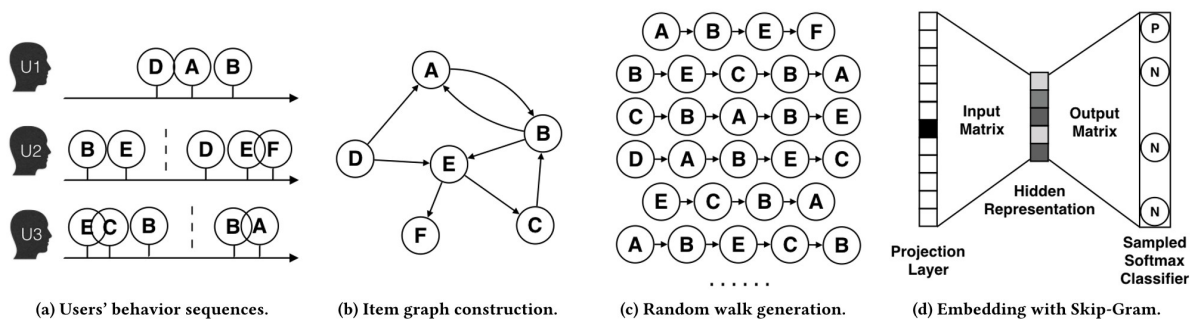
1. 노드로 이루어진 시퀀스를 그래프 내 랜덤 워크로 생성하고
2. Skip-Gram 방식을 적용해서 그래프 내 각 노드의 표현을 학습한다.
3. 주어진 노드 v 가 Context Node c 를 가질 조건부 확률을 사용한다.

2.2 Construction of Item Graph from User's Behaviors

과거의 CF 기반 메소드들은 오직 아이템 Co-Occurrence 만을 고려했다. 유저들의 선호도를 더 잘 반영하는 Sequential 정보를 무시했다. 그러나 사실 모든 유저 히스토리를 사용하는 것은 가능하지 않다.

1. Computational, Space 비용
2. 시간에 따라 유저의 흥미가 변화한다.

그러므로 실제에서는 시간 윈도우를 정하고 윈도우 내에서 유저의 행동을 선택한다. 이런 걸 세션 기반의 유저 행동이라고 한다. 세션 기반에서 사용하는 윈도우는 보통 한시간으로 한다.



세션 기반의 유저 행동을 얻은 뒤에 가중치를 두 아이템의 등장 빈도를 Edge로 가지는 그래프를 구축한다.

비정상적인 데이터를 필터링 할 필요가 있다.

- 클릭 후 다음 행동이 1초 이내인 경우
- 과도하게 액티브한 유저
- 소매업자들

2.3 Base Graph Embedding

weighted directed item graph를 얻은 뒤에, DeepWalk를 적용한다. Random Walk로 노드 시퀀스를 생성한 뒤, 시퀀스에 Skip-Gram 알고리즘을 동작시킨다.

2.4 Graph Embedding with Side Information

cold-start 문제를 다루기 위해 enhanced BGE를 사용해 cold-start item들에 부가 정보를 붙인다.

아이템 임베딩의 차원과 아이템의 부가 정보를 동일한 값으로 맞춘다.

아이템 임베딩 값을 average pooling을 해서 임베딩을 aggregate 한다.

2.5 Enhanced Graph Embedding with Side Information

문제는 여전히 남았다. 다른 종류의 부가 정보를 임베딩 과정에 통합하기.

마지막 임베딩에는 다른 종류의 부가 정보도 모두 동일하게 영향을 미친다고 가정하는 것은 현실적이지 못하다.

다른 종류의 부가 정보는 유저 행동 내 아이템의 co-occurrence에 서로 다르게 기여한다.

이러한 문제를 해결하기 위해 weighted average layer를 제안해서 부가 정보의 임베딩을 aggregate한다.

Sampled Softmax

Vocabulary가 크다면 Softmax를 모든 단어에 계산하는 비용이 크다. 이를 줄이기 위해 Target이 아닌 단어 중 일부를 제거하고 그 단어는 없었던 것 처럼 Softmax를 계산한다.

3.1 Offline Evaluation

AUC를 사용한다.

3.2 Online A/B Test

3.3 Case Study

4. System Deployment And Operation

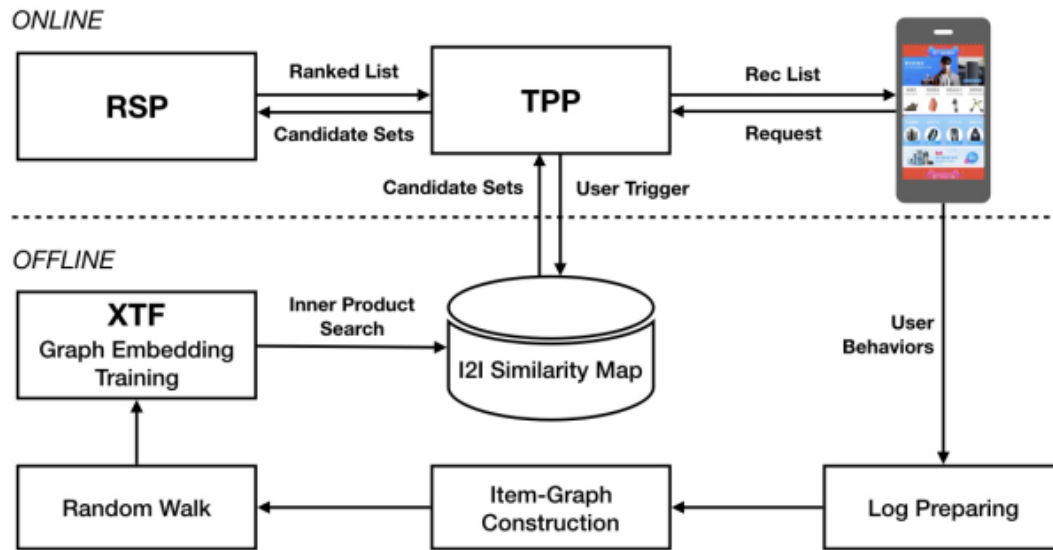


Figure 8: Architecture of the recommending platform in Taobao.

온라인과 오프라인 두 서버 시스템으로 구성된다.

- TPP (Taobao Personality Platform)
- RSP (Ranking Service Platform)
- 유저가 모바일 타오바오 어플을 실행하면, TPP는 유저의 최신 정보와 아이템 후보 셋을 오프라인 서버 시스템으로 가져온다. 그리고 RSP로 보내진다. RSP는 후보 셋 아이템들의 랭크를 파인 튜닝된 신경망으로 매기고 TPP로 결과를 보낸다. 타오바오를 방문하는 유저의 행동은 수집되고 오프라인 서버 시스템에 로그 데이터로 저장된다.

오프라인 서버 시스템의 워크 플로우 (6시간 내 완료)

- 3개월 간의 유저 행동 로그가 들어오면, 데이터 클렌징 과정 후에 아이템 그래프가 구축된다.
- 모든 그래프는 서브 그래프로 쪼개지고 병렬적으로 random walk를 진행해 노드 시퀀스를 생성한다.
- XTF 플랫폼을 사용해서 그래프 임베딩을 만든다.

RELATED WORK

5. 1 Graph Embeeding

많은 수의 연구에서 디자인된 임베딩 알고리즘은 3가지 카테고리로 분류 된다

- Factorization Method : LINE
- Deep Learning
- Random Walk

5. 2 Graph Embedding with Side Information