



DEEPM (huawei)

Abstract

복잡한 피쳐 간 상호작용을 학습하는 것 유저 행동들을 뒤로하고 은 중요하다 CTR을 최대화하는 것 추천 시스템을 위해.

대단한 혁신 들에도 불구하고, 현존의 방법들은 아직 편향성(bias)를 강하게 가지고 있는 것 처럼 보인다. 낮거나- 높은 차원의 상호 작용이나 전문화된 피쳐 엔지니어링에 대해서 .

이 연구에서는 우리는 보일 것이다. 가능하다는 것을 end-to-end 학습 모델을 도출하는 것이 강조하는 두 낮거나- 높은- 차원의 피쳐 상호작용을.

제안한 모델인, DeepFM 모델, 결합하는 추천을 위해 Factorization 강력한 부분과 새로운 신경망 구조를 피쳐 학습을 위한 딥러닝

비교함 최신의 와이드 앤 딥 모델 구글의, DeepFM은 가진다. 공유되는 입력을 이것의 와이드 와 딥 부분을 피쳐 엔지니어링을 할 필요없이 로우 데이터에 대해서

종합적인 실험들은 수행되는데 증명하기 위해 DeepFM 모델의 효과성과 효율성, CTR 예측을 위해 존재하는 벤치마크 데이터와 상업적 데이터에 대해

Introduction

CTR 예측은 크리티컬 하다 추천 시스템에서는 태스크는 예측하는 확률 유저가 추천되는 아이템을 클릭 할지.

많은 추천 시스템 들의 목적은 최대화하는 것이다 클릭 수를, 그리고 그래서 아이템들은 반환된다 유저에게 순위를 매겨 저서 추측된 CTR로; 그러나 다른 어플리케이션 시나리오 들 예를 들어 온라인 광고에서는 중요하다 수익을 개선하는 것이 그리고 랭킹 전략은 조정 될 수 있다. CTR X bid로 모든 후보들에 대해 여기에서 bid는 이득이다. 시스템이 받는 만약 아이템이 유저 들에게 클릭 될 때 발생하는.

두 경우에서, 확실하다 중요한 것은 CTR을 정확하게 예측 해야 한다는 점.

중요하다 CTR 예측을 위해 학습하는 것 implicit feature interactions을 유저 클릭 행동 에 숨겨져 있는

우리의 연구 주류 앱 마켓 에서의 는, 우리는 발견했다. 사람들이 종종 앱을 다운로드하는 것 음식 배달을 위해, 제안한다. 상호작용 앱 카테고리 와 타임 스탬프는 CTR을 위한 시그 널로 사용될 수 있다고. (2-order Interaction)

두번째 발견으로, 남성 10대는 슈팅 게임이나 RPG 게임들을 좋아한다는 것은, 의미한다 앱 카테고리 와 유저의 성별과 나이의 상호 작용은 CTR을 위한 다른 시그널이 될 수 있 다는 것. (3 - order interaction)

일반적으로, 피쳐 간의 상호작용 유저 클릭 행동 뒤의 는 엄청나게 복잡할 수 있다 저-차원 과 고차원의 피쳐 상호작용에서 중요한역할을 하기 때문에.

분석에 따르면 와이드 앤 딥 모델의 구글꺼임, 고려하는 것 저- 그리고 고차원 피쳐 상호 작용을 동시에 은 불러온다 부가적인 개성을 둘을 따로 다루는 것보다

주요 챌린지는 효율적으로 모델링하는 거다 피쳐 상호작용을

몇 몇의 피쳐 상호 작용은 쉽게 이해 될 수 있지만, 그래서 전문가들 에게도 디자인 될 수 있지만,

그러나 거의 모든 다른 피쳐 상호작용은 데이터 속에 숨겨져 있고 priori(예를 들어, 전통 적인 연관 관계 "기저귀와 맥주"는 데이터로 부터 마이니 되었다. 전문가 들에게 발견 되는 것이 아니라)를 식별하기 힘들다. 오직 자동적으로 머신 러닝에 의해서 캐치 될 수 있다

심지어 이해하기 쉬운 상호작용에 대해서도, 피쳐의 수가 많아지면 전문가가 발견하기 힘 들다.

간단 함에도 불구하고, 일반화된 선형 모델들의 FTRL과 같이 실전에서는 낮은 퍼포먼스 를 보인다.

그러나 선형 모델은 피쳐 간 상호작용을 학습하기 부족하고, 관행은 메뉴얼하게 pairwise 피쳐 상호작용을 피쳐 벡터에 포함하는 것이다.

다음과 같은 메소드는 어렵다 일반화 하기 모델로 고차원 피쳐 상호 작용이나 전혀 나오지 않거나 드물게 훈련 데이터에 등장하는 것은.

Factorization 머신들은 모델링한다. pairwise 피쳐 상호작용을 latent vectors 를 내적 해서 피쳐들간을 그리고 보여준다 꽤 괜찮은 결과를

기초적인 FM이 고차원의 피쳐 상호작용을 모델링 하지만 실전에서는 2차 피쳐 상호작용 만 고려된다. 복잡성이 높기 때문에

강력한 접근법으로 피쳐 표현을 학습하기 위한, 딥 뉴럴 네트워크는 가진다 잠재성 복잡한 피쳐 상호작용을 학습할 수 있는.

몇 몇의 아이디어는 CNN이나 RNN 을 사용해서 CTR 예측 하기로 확장 되었다.

그러나 CNN 기반의 모델들은 편향 되었다. 이웃된 피쳐들 간의 상호 작용으로 그치만, RNN-기반의 모델들은 순서 의존성을 가지는 클릭 데이터에 적합했다.

Factorization-machine supported Neural Network (FNN)도 나왔다.

이 모델은 사전-학습한다 FM을 DNN을 적용하기 전에, 그래서 FM의 가용성에 제한된다 피쳐 상호작용은 연구 되었는데, 상품 레이어를 Embedding과 Fully-Connected 레이어 사이에 추가하는데 이름이 Product-based Neural Network 다.

저- 그리고 고 차원의 피쳐 상호 작용 들을 모델링 하기 위해 cheng은 제안했다. 흥미로운 하이브리드 네트워크 구조를 그게 바로 와이드 앤 딥 이다.

- 새로운 모델은 저차원 피쳐 상호작용을 FM으로 고차원 피쳐 상호작용을 DNN으로 와이드 앤 딥 모델과는 다르게, DeepFM은 피쳐 엔지니어링 없이 간다.
- 와이드 앤 딥과는 다른 구조기 때문에 효율적인 학습이 가능하다

Our Approach

가정하자 데이터 셋을 트레이닝을 위해 n 개의 인스턴스 들로 구성되어 있는 x 는 m 개 필드를 가지는 데이터 레코드다.

유저와 아이템 페어를 포함하는 그리고 y 는 0-1 두 값을 가진다.

1은 의미한다. 유저가 클릭한 아이템 그리고 아니면 0.

x 는 포함한다. 범주화된 필드들 (성별, 위치)

각 범주화된 필드는 표현되는데 원핫 인코딩 벡터로, 연속된 필드는 그 값 자체로 표현,

그리고 각 인스턴스는 (x, y) 로 변환된다 $x = [x_field1, x_field2, x_field3, x_fieldm]$ 로 벡터이다. 벡터 표현식이 된다.

일반적으로 x 는 고 차원이고 극도로 sparse하다

CTR 예측 Task는 예측 모델을 세우는 것이다 유저가 특정 앱 내 주어진 배경으로 클릭 확률을 예측하는

DeepFM

우리는 목표로 한다 학습하는 것을 저- 고차원 피쳐 상호작용 둘다 학습하는 것을

마침내 DeepFM을 제시한다. FM 컴포넌트와 Deep 컴포넌트는 입력을 공유한다.

피쳐 i 에 대해, 스칼라 w_i 는 1st order 가중치를 부여한다. latent vector V_i 는 사용된다 측정하는데 영향도를 다른 피쳐들과의 상호 관계를


V_i 는 FM 컴포넌트 내부로 피딩되어 2nd order 피쳐 상호관계를 모델링에 사용되고 딥 컴포넌트에 피드되어 고-차원 피쳐 상호 관계를 모델링하는데 사용된다.

모든 파라미터들, w_i , V_i 그리고 네트워크 파라미터들은 조인트하게 학습된다 결합된 예측 모델을 위해

user						movie (item)					time	rating	
$\mathbf{x}^{(i)}$	\mathbf{u}_1	\mathbf{u}_2	\mathbf{u}_3	\mathbf{u}_4	...	\mathbf{i}_1	\mathbf{i}_2	\mathbf{i}_3	\mathbf{i}_3	...	\mathbf{t}	\mathbf{r}	$\mathbf{y}^{(i)}$
$\mathbf{x}^{(1)}$	1	0	0	0	...	1	0	0	0	...	2	5	$\mathbf{y}^{(1)}$
$\mathbf{x}^{(2)}$	0	1	0	0	...	0	0	1	0	...	18	1	$\mathbf{y}^{(2)}$
$\mathbf{x}^{(3)}$	0	1	0	0	...	0	0	0	1	...	6	2	$\mathbf{y}^{(3)}$
$\mathbf{x}^{(4)}$	0	0	1	0	...	0	1	0	0	...	12	3	$\mathbf{y}^{(4)}$
$\mathbf{x}^{(5)}$	1	0	0	0	...	0	0	1	0	...	3	5	$\mathbf{y}^{(5)}$
:	:	:	:	:	:	:	:	:	:	:	:	:	:
$\mathbf{x}^{(m)}$	0	0	0	1	...	0	1	0	0	...	9	4	$\mathbf{y}^{(m)}$

user 필드, movie 필드, time 필드, label

user 필드 (남, 녀)



FM 컴포넌트는 팩토리제이션 머신이다

피쳐 들에 대하여 linear interaction 으로 모델링(order -1)

FM 모델들의 pairwise 피쳐 상호 작용을 feature latent vector들의 내적으로 모델링(order - 2)

데이터 셋이 sparse 할 때에 훨씬 order 2 상호 작용을 잘 캐치 한다.

이전의 접근법에선 피쳐가 같이 등장할 때에만 학습이 되었다

하지만 FM 에서는 벡터 V_1, V_2 로 학습한다 i 나 j 가 데이터 레코드에 등장하더라도

그러므로 피쳐 상호 작용 상 전혀 등장 않거나 드물게 등장하는 경우도 학습이 된다